

人定主线，AI 精排

用 Claude Code 做 villa Beamer

段宇乐

2026 年 6 月 11 日



北京大学 **VILLA**
PEKING UNIVERSITY Visual-Information Intelligent Learning LAB

手工精排一套组会 beamer，往往一晚上就没了：逐页对齐图文、反复编译看溢出、字号留白来回试。


- 想清楚“讲什么”只占两成精力，八成耗在排版
- 改一张图，整页又得重排

这套 make-slides skill 把分工反过来：你定主线，AI 干精排。

4

三类适用任务与实验

偏好迁移的定性图：更“PickScore 味”
结论三·偏好迁移



对比、锐度、饱和、bokeh 普遍增强——确是人类偏好方向的提升，但也带来轻微的风格同质化（“premium render”签名感）。



图 1: skill 的产出

按 “这一步要不要和人来回讨论” 切分，而不是一把梭全交给 AI：

人 · 交互

阶段 1 · 大纲设计

定主旨、重组逻辑、每页讲什么。最难、最需要你，反复对齐。

AI · 确定性扇出

阶段 2 找图 / 阶段 3 排版

目标定死后并发干，每图、每页各一个 agent。

旁白：子 agent 中途无法问你，所以把要讨论的都收在阶段 1。

两个文件当全程脊柱，后面每个阶段都读它，不靠 agent 猜：

`narrative.md` · 主线

一句话主旨 / 重组逻辑 (≠ 论文目录) / 关键洞见。

`outline.yaml` · 每页内容

逐帧的标题、正文、最终公式、版式、图规格。


防止 AI 退回照搬原文的流水账。

排版阶段只填、不猜。


旁白：主线写对了，扇出再多 agent 也不跑偏。

agent 有视觉——这是达到手工级的关键。每页都走一个小循环：

- 写 frames/<id>.tex，编译，渲染成 PNG
- Read 打开图亲眼看：溢出？图太大？像手排吗？
- 不满意就改，直到干净



每个 agent 用独立 build 目录、靠 TEXINPUTS 找资源，互不冲突；又共享同一份 preamble.tex，做到 “在 harness 里好看，就在成品里好看”。



一条线五个阶段：阶段 1 交互定纲，1.5 校公式，阶段 2、3 并发扇出找图与排版，最后阶段 4 合并终检。

1 背景与框架 Diffusion RL: 把采样当 policy rollout

每个 epoch: 采 prompt $c \rightarrow$ rollout $x_0^{(j)} \sim p_\theta(\cdot | c) \rightarrow$ reward $R^{(j)} \rightarrow$ advantage $A^{(j)} = R^{(j)} - b(c) \rightarrow$ 梯度上升

$$\nabla_\theta J(\theta) \approx \mathbb{E}[A \nabla_\theta \log p_\theta(\tau | c)], \quad \tau = (x_T, \dots, x_0).$$

两条主路线 + 一类旁支:

- **ODE $\rightarrow$ SDE**: 采样随机化成可写 logprob 的 policy (PPO/GRPO); 强依赖 sampler / 时间步 / CFG。
- **Forward-process**: 把终端 advantage 传回中间 x_t , 加权 denoising/velocity 目标。
- 偏好 / 蒸馏旁支: DPO 式, 把 preference 写成分类 / 排序 surrogate。

Diffusion RL 的通用任务 2026 年 6 月 11 日 段宇乐 7 / 38

(a) tikz 自绘概念图

2 条件与 CFG 为何有效 CFG 机制: 在已学好的方向上外推

训练时 condition dropout, 让同一模型既学 $v_{\text{cond}} \approx \mathbb{E}[u | x_t, t, c]$ 又学 $v_{\text{uncond}} \approx \mathbb{E}[u | x_t, t]$ 。推理时沿二者之差外推:

$$v_{\text{cfg}} = v_{\text{uncond}} + s(v_{\text{cond}} - v_{\text{uncond}}).$$

隐式 classifier guidance:

$$\text{score}_{\text{cfg}} = \nabla \log p(x_t) + s \nabla \log p(c | x_t),$$

相当于从 $p_{\text{cfg}} \propto p(x_t) p(c | x_t)^s$ 采样。


s 是推理 trick, 但它能放大, 是因为训练已经把条件方向准备好了。

Diffusion RL 的通用任务 2026 年 6 月 11 日 段宇乐 13 / 38

(b) 逐步稠密推导

概念图自己画、逐步公式照排，都不溢出、像手排。

4 三类适用任务与实验 窄指标: reward 涨得又快又干净



val 与 rollout 同步上升: Geneval val 0.73 $\rightarrow$ 0.82, OCR val 0.58 $\rightarrow$ 0.86。

数字上, 窄指标几乎总能涨。

(a) seaborn 重画的数据曲线

5 编辑: 更难的条件 T2I 与编辑: 形式相同, 条件语义不同
编辑学的是条件变换算子, 不是单纯条件生成

两者都是 $p(x | c)$, 但编辑的


$c = (\text{source image, instruction})$ 更像一个程序:

$$x_{\text{target}} = T_{\text{instruction}}(x_{\text{source}}).$$

source image 同时承担三类角色:

- 保留: 身份、构图、背景、光照、姿态;
- 修改: 颜色、物体、文字、局部属性;
- 定位 / 绑定: 例如“原来的蓝色物体在何处”。

“make the blue object red”——不能忽视 blue, 要先用它定位, 再在同一区域覆盖成 red。



(b) GPT-Image 生成的插画

拉数据重画的矢量曲线 + AI 生成的示意插画, 风格都贴合主题。

这份介绍 **deck** 本身，就是用这套流程做出来的。

你要做的只有：

- 复制本仓库开新坑
- 跟 Claude 说“把这篇 / 这个讲一讲”
- 陪它过一遍大纲（阶段 1，最值得花时间）
- 等它扇出找图与排版，收一份 `slides.pdf`

人定主线，AI 精排。